# LOG3430 - Méthodes de test et de validation du logiciel

# Laboratoire 3

TEST D'INTÉRACTIONS

Département de génie informatique et de génie logiciel École Polytechnique de Montréal



Automne 2021

# 1 Introduction

Dans ce laboratoire vous allez ajouter les fonctionnalités additionnelles dans votre système et implémenter les testes d'interactions correspondants.

# 2 Objectifs

Les objectifs généraux de ce laboratoire sont :

- 1. Apprendre a utiliser l'outil ACTS.
- 2. Mettre en place les tests d'interactions.

## 3 Tests d'interaction

Vous avez vu pendant le cours qu'il existe différentes approches vers le calcul de probabilités que un message est spam, calcul de combinaison des probabilités, création du vocabulaire, etc. Dans cette partie, vous allez ajouter la fonctionnalité dans votre système RENEGE pour permettre l'utilisateur de choisir le mode de fonctionnement qui lui convient le plus.

Pour assurer le bon fonctionnement du système amélioré, vous allez réaliser les tests d'interaction en utilisant l'outil ACTS.

## Les tâches

Tout d'abord, il faut ajouter la fonction dans le système RENEGE existant.

## Calcule de probabilité

La probabilité que un message est Spam peut être évalué soit comme :

$$P(spam|text) = P(spam) * \prod P(w_i|spam)$$
 (1)

ou en utilisant le logarithme comme:

$$logP(spam|text) = \sum logP(w_i|spam) + logP(spam)$$
 (2)

Dans la fonction is spam de module email\_analyzer.py il faut ajouter un paramètre qui va permettre de choisir la formule pour estimation de probabilité de message d'être spam ou ham.

### Calcul de combinaison de probabilité

La combinaison de probabilités peut être réalisé selon une de formules,  $k \in [0, 1]$ :

$$P(spam|text) = k * P(spam\_sub|text) + (1 - k) * P(spam\_body|text)$$
(3)

$$logP(spam|text) = k * logP(spam\_sub|text) + (1 - k) * logP(spam\_body|text)$$
 (4)

Dans la fonction is spam de module email\_analyzer.py il faut ajouter un paramètre qui va permettre de choisir la formule pour calculer la combinaison des probabilités.

	Calcul de proba-	Combinaison de	Création du vo-	Nettoyage du	l
	bilité	probabilité	cabulaire	texte	
0	multiplication	somme	1	0	
1	somme des logs	somme des logs	2	1	
2			3	2	
3			4	3	

Table 1 – Les paramètres du système

#### Création du vocabulaire

Quand on crée le vocabulaire, on peut avoir les restrictions pour la fréquence des mots qui vont apparaître. Par exemple, on peut ajouter tous les mots dans le dictionnaire, les mots avec la fréquence plus que 1,2,3, etc.

Dans la fonction create\_vocab de module vocabulary\_creator.py il faut ajouter un paramètre qui va permettre de choisir la fréquence des mots minimale pour ajouter le mot dans le dictionnaire. Les valeurs possibles seront : 1, 2, 3, 4.

## Nettoyage du texte

Pour nettoyer le texte, c'est possible d'enlever les 'stop words', faire le 'stemming' ou pas. Dans la fonction clean\_text du module text\_cleaner.py il faut ajouter un paramètre qui va permettre de choisir si les "stop words" sont enlevées ou pas et si "stemming" est fait ou pas. Les paramètres vont êtres suivant :

- 0 pour faire stemming et enlever "stop words".
- 1 pour ne pas faire stemming et enlever "stop words".
- 2 pour faire stemming et ne pas enlever les "stop words".
- 3 pour ne pas faire le stemming et pour ne pas enlever les "stop words".

#### Définition du spam

Dans la fonction process\_email du module renge.py il faut utiliser la fonction 'is\_spam' de email\_analyzer.py au lieu de prendre la valeur enregistrée (data['Spam']).

## Création de MCA

En considérant les paramètres décrits en haut et résumés dans la fig.1, il faut créer une matrice de couverture mixte en utilisant l'outil ACTS. L'outil est disponible a télécharger dans le moodle. Pour lancer l'interface graphique, il faut utiliser la commande :

$$java-jaracts\_3.0.jar$$

Après avoir créé le jeu de test il faut le sauvegarder en format csv. L'interaction maximale à utiliser est 3. Vous pouvez ajouter des limitations, si nécessaire.

## Exécution du jeu de test

Il faut ajouter une fonction dans main.py qui va lire le fichier csv avec le jeu de test et l'exécuter automatiquement. Après l'exécution, il faut analyser les résultats. Y'a-t-il des cas de tests qui réduisent la performance du système significativement?

# 4 Remarques

- Vous pouvez faire toutes les modifications nécessaires pour ajouter la fonctionnalité dans le système. Évidemment, il faudrait ajouter les paramètres additionnels dans la fonction classify\_emails et process\_emails du module renege.py.
- Il faudrait modifier la fonction evaluate() du module main.py, pour pouvoir utiliser aussi vos nouveaux modes de calculs.
- Il faut exécuter les cas des tests seulement pour la puissance 3.

## 5 Livrables attendus

Les livrables suivants sont attendus:

- Un rapport pour le laboratoire : 10 points. Rapport doit contenir :
  - Les conclusions pour les tests d'interaction. Quelle est la taille (taille N) de la matrice MCA pour la puissance 2, 3, 4, 5? Quel est l'accuracy de votre système pour chaque cas de test? Quelle configuration donne les meilleurs résultats? Avez vous trouver les défauts dans votre système?
- Le dossier COMPLET contenant le projet (tout les fichiers .py du système RENEGE amélioré et les fichier avec les tests générés par ACTS) : 10 points. **N'oubliez pas de bien commenter votre code**. Un code peu ou pas commenté sera pénalisé.

Le tout à remettre dans une seule archive **zip** avec le titre matricule1\_matricule3\_lab1.zip sur Moodle. Seulement une personne d'équipe doit remettre le travail.

Le rapport doit contenir le titre et numéro du laboratoire, les noms et matricules des coéquipiers ainsi que le numéro du groupe.

# 6 Information importante

- 1. Consultez le site Moodle du cours pour la date et l'heure limites de remise des fichiers (deux semaines après la première séance du laboratoire).
- 2. Un retard de [0,24h] sera pénalisé de 10%, de  $[24h,\,48h]$  de 20% et de plus de 48h de 50%.
- 3. Aucun plagiat n'est toléré. Vous devez soumettre juste le code, qui était fait par les membres de votre équipe.